

基于多因子组合与统计套利的量化选股策略

李博言 中科院数学与系统科学研究院

本报告以沪深 300 指数成分股中在 2023 年 1 月至 2026 年 3 月始终存续的 243 只股票为样本，用以上时间内的月度价格、基本面数据，构建并回测了动量、价值、规模、盈利、投资五个经典因子。通过对各因子的信息系数 (IC) 与信息比率 (IR) 分析发现：规模因子表现最强 (平均 IC=0.288, IR=1.71)，盈利因子次之 (平均 IC=0.036, IR=0.39)，而动量、价值、投资因子在样本期内预测能力微弱或为负。

在多因子组合构建中，对比了等权合成与滚动历史 IC 均值加权合成两种方式。分组回测中，滚动 IC 加权方式的多空组合年化收益达到 99.19%，夏普比率为 7.18，显著优于等权组合 (年化 41.09%，夏普 4.60)，且最大回撤基本持平 (约-2.9%)，验证了动态加权能够有效适应因子有效性的时变特征。滚动 IC 加权方式的“多组”累计净值是初始的 2.25 倍左右，显著跑赢同期沪深 300 指数。

进一步采用 LightGBM 模型进行因子合成，两种正则化配置下的年化收益约 79%~81%，夏普比率约 6.0~6.9，均优于等权但低于滚动 IC 加权。正则化 (早停与 gamma 约束) 降低了最大回撤 (从-4.23% 改善至-3.67%)，体现了对尾部风险的控制能力。特征重要性分析表明，无正则化时模型过度依赖规模因子，有正则化后各因子重要性动态调整，实现了“稳定性与适应性”的权衡。

此外，本报告还以中信建投 (601066.SH) 与中金公司 (601995.SH) 为例，进行了协整检验与配对交易回测。全样本协整检验 p 值小于 0.05，滚动估计对冲比率后执行阈值交易，策略年化收益 15.32%，夏普比率 0.98，显著跑赢单一资产基准，验证了统计套利在这两只股票上的有效性。

1 数据与因子构建

选取 2023 年 1 月至 2026 年 3 月期间始终在沪深 300 指数中的股票作为固定股票池 (共 243 只)。采用月度调仓频率，分别构建五个因子并进行预处理，采用几种方式实现因子组合并分组回测。所有数据通过 Tushare 获取，回测暂未考虑交易成本。

动量因子

动量因子采用经典的“12-1”形式，即计算每只股票过去 12 个月的累计收益率，但剔除最近 1 个月。具体地，每月最后一个交易日，获取股票后复权收盘价，因子值计算公式为：

$$\text{Momentum}_{i,t} = \frac{P_{i,t-1}}{P_{i,t-13}} - 1,$$

其中 $P_{i,t-1}$ 为股票 i 在 $t-1$ 月末的后复权收盘价， $P_{i,t-13}$ 为 $t-13$ 月末的后复权收盘价。采用后复权月线数据，并通过前向填充处理停牌导致的缺失值。

价值因子

价值因子采用账面市值比 (BP)，定义为归属母公司股东的权益除以总市值。为简化计算并保证数据时效性，直接使用 Tushare 提供的市净率 (PB) 字段，并取倒数：

$$\text{BP}_{i,t} = \frac{1}{\text{PB}_{i,t}}.$$

对于净资产为负或 PB 缺失的股票，因子值先设为缺失值，经 MAD 法处理极大值后，进行标准化后，做行业与市值双重中性化，再次标准化，最后将此前设为缺失的因子值填充为 0。

规模因子

以小市值效应为基础，取总市值的倒数，使得数值越大代表市值越小：

$$\text{Size}_{i,t} = \frac{1}{\text{MarketCap}_{i,t}}.$$

经 MAD 法处理极值后，进行 Z-score 标准化。

盈利因子

使用净资产收益率（ROE）衡量公司盈利能力，ROE 越高预期收益越高：

$$\text{Profit}_{i,t} = \text{ROE}_{i,t}.$$

经 3σ 法处理极值、Z-score 标准化后，做行业与市值双重中性化，再次标准化。

投资因子

以总资产同比增长率取反表示投资保守程度，增长率越高（扩张越激进）则得分越低：

$$\text{Investment}_{i,t} = - \left(\frac{\text{TotalAssets}_{i,t}}{\text{TotalAssets}_{i,t-1}} - 1 \right).$$

经 MAD 法处理极值（ ± 5 倍 MAD）、Z-score 标准化后，做行业与市值双重中性化，再次标准化。

2 因子 IC 与 IR 分析

2.1 信息系数 (IC)、信息比率 (IR)

信息系数 (Information Coefficient, IC) 衡量因子值与股票未来收益率之间的相关性，是因子预测能力的核心度量指标之一。我使用对极端值不敏感的 Spearman 秩相关系数 (Rank IC)，更能反映因子排序与收益排序的一致性。

设股票 i 在第 t 期因子值为 $F_{i,t}$ ，下一期收益率为 $R_{i,t+1}$ 。则其当期的 Rank IC 定义为：

$$\text{IC}_{i,t} = \text{corr}(\text{rank}(F_{i,t}), \text{rank}(R_{i,t+1})),$$

其中 $\text{rank}(\cdot)$ 表示将数值转换为升序排名。

信息比率 (Information Ratio, IR) 衡量因子预测能力的稳定性，定义为 IC 的均值与 IC 标准差之比：

$$\text{IR}_i = \frac{\text{Mean}(\text{IC}_{i,t})}{\text{Std}(\text{IC}_{i,t})}.$$

IR 反映了因子在时间序列上的可靠性。高 IR 意味着因子不仅在平均意义上有预测能力，而且表现相对稳定。为了动态评估因子的近期表现，可以计算滚动窗口内的 IR，例如过去 12 个月的滚动 IR：

$$\text{IR}_{i,t}^{\text{roll}} = \frac{\text{Mean}(\text{IC}_{i,t-11:t})}{\text{Std}(\text{IC}_{i,t-11:t})}.$$

滚动 IR 有助于捕捉因子有效性的衰减或增强。

2.2 因子 IC、IR 与滚动 IR 计算及结果分析

在完成五个因子（动量、规模、价值、盈利、投资）的预处理与面板对齐后，本节计算各因子的信息系数 (IC) 与信息比率 (IR)，并分析其预测能力与稳定性。数据跨度为 2024 年 2 月至 2026 年 2 月，共 25 个月度截面。未来收益定义为个股下个月的后复权收益率（即 t 月末因子对应 $t+1$ 月收益）。IC 采用 Spearman 秩相关系数逐月计算，全样本 IR 为 IC 均值与 IC 标准差之比，同时以 12 个月为窗口计算滚动 IR。

计算得到各因子的统计指标如表 1所示。

Table 1: 五因子 IC 与 IR 统计指标

因子	平均 IC	IC 标准差	IR
动量因子	-0.0170	0.2695	-0.0631
规模因子	0.2884	0.1685	1.7113
价值因子	0.0122	0.0886	0.1372
盈利因子	0.0355	0.0912	0.3892
投资因子	-0.0045	0.0664	-0.0672




Figure 1: 五因子 IC 时间序列 (左) 与 12 个月滚动 IR (右)

从结果可见，规模因子表现出最强的预测能力，平均 IC 为 0.2884，IR 高达 1.71，远高于 0.5 的实用阈值，说明市值倒数因子在样本期内具有稳定且显著的正向选股效果（小市值效应明显）。盈利因子平均 IC 为 0.0355，IR 为 0.3892，虽未达到 0.5 的稳健阈值，但已具备一定的正向预测能力，表明高 ROE 公司在样本期内整体表现优于低 ROE 公司，可作为辅助信号使用。价值因子平均 IC 仅为 0.0122，IR 为 0.1372，预测能力微弱且不稳定，这与同期市场风格偏向成长、传统估值指标阶段性失效的宏观背景一致。动量因子平均 IC 为负 (-0.0170)，IR 为负，表明在样本期内 A 股市场呈现反转效应，过去 12 个月的强势股在次月反而表现较弱。投资因子平均 IC 为 -0.0045，IR 为 -0.0672，方向为负且数值接近零，说明总资产增长率（取反后）在样本期内几乎没有选股能

力，可能因资产增长率对 A 股公司收益的解释力较弱或存在其他混杂因素。

图 1 展示了五个因子的 IC 时间序列（左列）及 12 个月滚动 IR（右列）。从 IC 序列看，规模因子的 IC 大部分月份为正且波动相对较小；盈利因子的 IC 正负交替但正向月份略多；动量因子的 IC 正负交替剧烈；价值因子的 IC 长期在零轴附近徘徊；投资因子的 IC 则基本围绕零轴波动，无明显趋势。滚动 IR 曲线进一步印证：规模因子的滚动 IR 在大部分时间保持在 0.5 以上，甚至多次超过 1.0；盈利因子的滚动 IR 在部分时段接近 0.5 但整体偏低；动量、价值、投资因子的滚动 IR 则长期低于 0.5，不具备稳定的预测能力。

综上，在 2024 年 2 月至 2026 年 2 月的样本期内，规模因子具有优秀的选股能力，可直接作为正向信号使用；盈利因子具备一定的辅助价值，可适当赋予正权重；价值因子与动量因子效果不佳，可通过取反方向或降低权重加以利用；投资因子基本无效，可以赋予极低权重。

3 多因子组合构建：等权与滚动历史 IC 加权

在完成五个因子（动量、规模、价值、盈利、投资）的预处理与单因子 IC 评估后，进一步构建多因子组合，并对比不同加权方式的选股效果。核心目标是：通过合成综合得分，筛选出未来收益最高的股票组合，同时检验动态加权（基于历史 IC 均值）是否优于静态等权。

等权组合（基准）：每个因子赋予相同的权重：

$$\text{Score}_{i,t}^{\text{eq}} = \frac{1}{K} \sum_{k=1}^K F_{k,i,t},$$

其中 $K = 5$ ， $F_{k,i,t}$ 为因子 k 在 t 月末对股票 i 的标准化值。该权重在整个回测期内恒定，不依赖任何历史信息，因此完全无未来偏差，适合作为基准。

滚动历史 IC 均值加权（避免使用未来信息）：为了动态适应因子有效性的变化，采用滚动历史 IC 均值作为权重。具体步骤如下：

- 对于每个调仓日 t ，计算每个因子在过去 12 个月（ $t-12$ 至 $t-1$ ）的历史 IC 均值。注意，IC 的计算本身需要使用因子值与下月收益，但在 t 时刻， t 月的 IC（即当期 IC）尚不可知，因此只使用 t 月之前的历史 IC。
- 对 IC 序列计算滚动均值（窗口 12 个月，最小期数设为 1，即初期用所有可用历史 IC）。
- 将各因子的滚动 IC 均值按绝对值归一化，得到权重：

$$w_{k,t} = \frac{\text{RollingICMean}_{k,t}}{\sum_{j=1}^K |\text{RollingICMean}_{j,t}|}.$$

该权重保留了 IC 的符号：若某因子历史 IC 均值为正，则赋予正权重；若为负，则赋予负权重，自动实现反向使用。

- 合成综合得分：

$$\text{Score}_{i,t}^{\text{hist}} = \sum_{k=1}^K w_{k,t} \cdot F_{k,i,t}.$$

由于权重完全基于 t 时刻之前的历史 IC 计算，该过程不包含任何未来信息，符合实盘逻辑。

在每个调仓日 t ，将综合得分从低到高排序，等频分为 5 组（组 1 为最低分，组 5 为最高分）。计算每组内所有股票在下个月的平均收益率（等权），并构建多空组合：买入组 5、卖出组 1。回测区间为 2024 年 2 月至 2026 年 2 月，共 25 个月度截面。主要绩效指标如表 2 所示。

Table 2: 多因子组合绩效对比

组合	年化收益	年化波动	夏普比率	最大回撤	胜率
等权组合	41.09%	8.93%	4.60	-2.73%	84.00%
滚动历史 IC 均值	99.19%	13.82%	7.18	-2.94%	92.00%

从结果可见，滚动历史 IC 均值加权组合在年化收益（99.19% vs 41.09%）、夏普比率（7.18 vs 4.60）和胜率（92% vs 84%）上均显著优于等权组合，而最大回撤基本相当（-2.94% vs -2.73%）。这表明动态加权能够有效利用因子历史表现的信息，提升组合的选股能力。等权组合由于赋予所有因子相同权重，受到动量、投资等无效因子的拖累，收益相对平庸。

图 2 展示了两种组合的分组累计净值曲线（左列）及多空累计净值对比（右列）。从分组曲线看，滚动历史 IC 均值组合的组 5（高分）净值曲线远高于组 1（低分），单调性非常明显；而等权组合的分组差异相对较小。多空累计净值曲线进一步显示，滚动历史 IC 均值组合的净值增长更为陡峭，且稳定性更高，优于等权组合，以及同期沪深 300 指数。



Figure 2: 因子的等权组合与历史 IC 加权组合的收益率

本实验验证了在多因子模型中，采用滚动历史 IC 均值进行动态加权显著优于简单等权。该方法仅使用调仓日前已知的历史信息，无未来偏差，且能够自动适应因子有效性的时变特征。对于 IC 为负的因子（如动量、投资），滚动均值会自动产生负权重，相当于反向使用，进一步提升了组合的稳健性。

4 多因子组合构建：机器学习 LightGBM

4.1 基于 LightGBM 的因子合成

LightGBM 在 XGBoost 基础上针对大规模高维数据优化，进行了采用基于直方图的决策树算法、单边梯度采样以及互斥特征捆绑等创新。我们之前构建了五个因子，并通过等权组合与滚动历史 IC 加权组合验证了动态加权的有效性。本节进一步引入 LightGBM 模型，将五个因子作为特征、未来一个月收益率作为标签，采用严格的滚动训练框架生成机器学习合成因子。为探索正则化手段对模型泛化能力的影响，设计了两种配置：（1）仅对四个核心超参数（num_leaves、learning_rate、reg_lambda、reg_alpha）进行网格搜索，其余参数使用 LightGBM 默认值（无显式正则化）；（2）在上述搜索基础上，固定设置 gamma=0.1、min_child_samples=20、subsample=1.0、colsample_bytree=1.0，并在最终模型训练中引入早停（early_stopping_rounds=20，验证集为最近一个月）。两种配置均采用滚动时间序列交叉验证（3 折）选择最佳参数，前 6 个月使用滚动 IC 加权得分填充，回测分为 5 组。

无正则化和有正则化两种配置共享相同的搜索空间：

- num_leaves: 15, 20
- learning_rate: 0.03, 0.04, 0.05
- reg_lambda: 0.5, 1.0
- reg_alpha: 0.0, 0.1, 0.3

基础参数固定：feature_fraction=0.8, bagging_fraction=0.8, bagging_freq=5, n_estimators=100（交叉验证时）。最终模型训练时，无正则化配置使用 n_estimators=200，有正则化配置使用 n_estimators=500 配合早停。

表 3汇总了等权组合、滚动 IC 加权组合以及两种 LightGBM 配置的主要绩效指标。

Table 3: 多因子组合绩效对比（多空组合）

组合	年化收益	年化波动	夏普比率	最大回撤	胜率
等权组合	41.09%	8.93%	4.60	-2.73%	84.00%
滚动 IC 加权	99.19%	13.82%	7.18	-2.94%	92.00%
LightGBM（无正则化）	80.57%	11.71%	6.88	-4.23%	88.00%
LightGBM（有正则化）	79.25%	13.16%	6.02	-3.67%	92.00%

从结果可见，两种 LightGBM 配置的年化收益（约 79%）均显著高于等权组合（41.09%），但低于滚动 IC 加权组合（99.19%）。无正则化配置的夏普比率（6.88）略高于有正则化配置（6.02），但最大回撤也更大。有正则化配置通过早停和 gamma=0.1 降低了回撤（-3.67%），提高了胜率，但同时也牺牲了部分收益和夏普。




Figure 3: LightGBM 组合（无正则化）：分组累计净值与多空对比




Figure 4: LightGBM 组合（有正则化）：分组累计净值与多空对比

图 3 和图 4 中展示了无正则化与有正则化 LightGBM 组合的分组累计净值及多空组合累计净值。从分组净值曲线可见，两种配置的组 5（高分）与组 1（低分）之间均呈现明显分化，单调性良好。无正则化配置的高分组净值在后期波动更大，导致多空累计净值曲线出现回撤；有正则化配置的高分组净值更为平滑，多空曲线稳定性提升，但整体累计收益略低。左下角的多空累计净值对比显示，两种配置的前 6 个月均与 IC 加权重合（填充策略），第 7 个月后才开始分化，但均未能超越 IC 加权。右下角的月度收益率对比中，有正则化配置的极端负收益月份较少，体现了正则化对尾部风险的抑制作用。

本实验中，增加 $\text{gamma}=0.1$ 和早停并未带来夏普比率的提升，反而略微降低。尽管如此，有正则化配置的最大回撤从 -4.23% 改善至 -3.67%，表明其对极端风险有一定控制作用。两种 LightGBM 配置均能有效合成因子，收益显著优于等权组合，但均未超越滚动 IC 加权。在有限数据下，简单的线性动态加权（IC 滚动均值）表现出更强的稳健性。正则化手段（早停、设置大于 0 的 gamma ）对最大回撤有一定改善。

4.2 因子重要性分析

LightGBM 提供了多种衡量特征重要性的指标，其中最为常用的两种是 **split**（分裂次数）和 **gain**（信息增益）。**split** 统计的是每个特征在所有决策树中被用作分裂节点的总次数，它反映的是特征参与的“频率”。而 **gain** 统计的是每个特征在所有分裂节点上带来的目标函数（如均方误差 MSE）的总减少量，即累计增益。在量化因子合成的场景中，**gain** 通常比 **split** 更有意义，因为它不仅看特征被用了多少次，还看每次使用对模型性能的实际贡献。

Gain 的计算原理 对于每棵树，LightGBM 在每次分裂时会计算分裂前后的损失函数变化（即增益）。设分裂前的损失为 L_{parent} ，分裂后左、右子节点的损失分别为 L_{left} 和 L_{right} ，则该分裂带来的增益为：

$$\text{Gain} = L_{\text{parent}} - (L_{\text{left}} + L_{\text{right}}) - \gamma$$

其中 γ 是分裂所需的最小增益阈值（正则化参数）。增益越大，说明该分裂点对降低预测误差的贡献越大。每个特征的最终 **gain** 值就是该特征在所有树、所有分裂节点上增益的累加和。

Gain 与 Split 的对比

- **Split 重要性**: 容易受到特征取值分布的影响。如果一个特征有较多取值（例如连续值特征被离散化为较多箱子），它可能更频繁地被选作分裂点，即使每次分裂带来的增益很小。在量化数据中，某些技术因子可能因为波动剧烈而被频繁使用，但实际预测能力有限。
- **Gain 重要性**: 直接衡量预测贡献，更能反映特征的本质影响。一个特征哪怕只被使用了几次，只要每次分裂都大幅降低了损失，它的 Gain 就会很高。因此，在因子筛选或模型解释时，优先使用 `importance_type='gain'`。

分析 LightGBM 内置的特征重要性给出的特征重要性的时序变化（归一化 gain）折线图，可以得出以下结论：

(1) 无正则化条件下，规模因子占据绝对主导地位。在该设定下（无早停、无 `gamma` 约束），规模因子的归一化重要性始终维持在最高水平，且显著高于其他四个因子。这表明模型过度依赖规模这一单一信号，将其作为预测未来收益的最核心依据。这种极端的权重分配可能导致策略风格暴露过于集中（市值因子暴露过大），一旦规模风格发生剧烈反转，组合将承受较大回撤——这与无正则化配置下最大回撤（-4.29%）相对较高的结果一致。

(2) 有正则化条件下，特征重要性的剧烈波动反映了模型对因子时效性的更敏感响应。引入固定 `gamma=0.1` 和早停后，规模因子虽然仍是最重要的因子（多数月份排名第一），但各因子（包括规模、盈利、价值等）的重要性不再平稳，而是呈现出频繁的上下跳变。这种现象并非模型的缺陷，而是正则化迫使模型在每个滚动窗口内选择更适应近期市场状态的因子组合：当某个因子的历史预测能力在验证集上快速下降时，模型会迅速降低其权重甚至将其边缘化。因此，重要性的剧烈波动恰好体现了正则化模型对因子有效性的“动态监控”能力。

(3) 两种设定的对比揭示了“稳定性 vs 适应性”的权衡。无正则化模型选择了最“简便”的路径——长期依赖规模因子，重要性近乎静态，但因此丧失了对其他因子信号变化的响应能力，导致回测后期回撤扩大。有正则化模型虽然重要性波动剧烈，但这种波动反映了模型在每个时期都试图寻找最优的因子组合，从而在控制回撤方面取得了一定改善（最大回撤从 -4.29% 降至 -3.67%），尽管代价是年化收益和夏普比率略有牺牲。

综上所述，规模因子在样本期内具有最强的预测能力，但其绝对主导地位容易引发风格过度集中风险。正则化通过引入分裂增益门槛和早停，促使模型动态调整特征重要性权重，尽管带来了明显的时序波动，但也增强了对尾部风险的控制。




Figure 5: LightGBM 的因子重要性无正则化

5 协整与配对交易

配对交易是一种基于统计套利的市场中性策略，其核心是利用两只具有相似基本面背景的股票之间长期稳定的均衡关系获利。当配对的品种价差偏离历史均值时，通过做空价格较高的品种同时买进价格较低的品种，等待它们回归到长期均衡关系后平仓。该策略不依赖市场整体方向，因此可以有效对冲系统性风险。配对交易能够成立的前提是两只股票之间存在协整关系。协整意味着两个非平稳时间序列的线性组合是平稳的，它们的价差会表现出均值回归特性——当价差过大时预期缩小，价差过小时预期扩大。




Figure 6: LightGBM 的因子重要性有正则化

从协整检验到交易信号的构建 在确认存在协整关系之后，需要确定具体的交易规则。首先，由回归得到的系数 β 表示每持有 1 股股票 p 需要同时持有 β 股股票 q 来对冲市场风险，使得组合的价差 $p_t - \beta q_t$ 围绕零均值波动。为了生成可比较的交易信号，通常将价差标准化为 Z-Score：

$$Z_t = \frac{(p_t - \beta q_t) - \mu_t}{\sigma_t},$$

其中 μ_t 和 σ_t 是过去一段固定长度窗口内价差的均值和标准差。滚动窗口的使用能够适应市场结构的变化，避免固定参数失效。

经典的配对交易采用阈值规则。当 Z-Score 超过某个正阈值（例如 +2）时，认为价差过高，预期未来会向下回归，因此采取做空价差的策略：卖出 1 股股票 p ，同时买入 β 股股票 q 。反之，当 Z-Score 低于负阈值（例如 -2）时，做多价差：买入 1 股股票 p ，卖出 β 股股票 q 。当 Z-Score 回到接近零的平仓阈值（例如 $|Z| < 0.5$ ）时，认为价差已经回归，将所有头寸平仓。此外，通常还会设置一个更宽的止损阈值（如 $|Z| > 3$ ），以防协整关系暂时失效导致巨大亏损。

实验步骤

选取中信建投（601066.SH）与中金公司（601995.SH）两只券商股，在 2024 年 1 月 1 日至 2026 年 4 月 20 日的时间区间内，检验协整关系并执行配对交易回测。使用前复权日收盘价，确保价格序列连续。首先采用 ADF 检验，两序列是一阶单整的，之后采用 Engle-Granger 两步法对价格序列进行协整检验。

确认协整后，通过线性回归估计对冲比率 β （用中金公司价格解释中信建投价格）。价差定义为中信建投价格减去 β 倍中金公司价格。为消除量纲并生成可比信号，滚动计算价差 30 个交易日的均值和标准差，得到 Z-Score 序列。在回测中采用滚动估计的方式估计对冲比率 β_t ，以消除前视偏差。具体地，设定估计窗口长度为 120 个交易日，对于每个交易日 t （从第 30 天之后开始），使用过去 30 天的价格数据拟合线性回归 $A = \alpha + \beta B$ ，得到该时点的 β_t 。随后，利用 β_t 计算当日价差 $\text{spread}_t = A_t - \beta_t B_t$ 。为生成标准化信号，再滚动计算价差过去 30 个交易日的均值和标准差，得到 Z-Score 序列。

交易规则：当 Z-Score 大于 2.0 时做空价差（卖出中信建投、买入中金公司）；小于 -2.0 时做多价差（买入中信建投、卖出中金公司）；当 Z-Score 绝对值小于 0.5 时平仓。仓位信号向前填充，确保开仓后持续持有。

策略日收益率计算为：前一日仓位乘以（中信建投当日收益率减去前一日对冲比率 β_{t-1} 倍的中金公司当日收益率）。累乘得到策略净值曲线，并以中信建投单资产净值作为基准。绩效指标包括累计收益率、年化收益率、夏普比率（假设无风险利率为零）和最大回撤。

实验结果

全样本协整检验 p 值为 0.011353（小于 0.05），表明两只券商股在样本期内存在统计显著的长期均衡关系，具备配对交易的理论基础。采用滚动估计，对冲比率 β_t 随时间变化，其平均值约为 0.85，反映了两家公司相对

估值的平均比例。由于每个时点的 β_t 仅基于历史数据，回测结果更贴近实盘。回测的绩效统计如下：

- 累计收益率：36.10%
- 年化收益率：15.32%
- 夏普比率：0.9811
- 最大回撤：-11.37%

图 7展示了价格走势、Z-Score 与交易信号、策略净值与基准净值，直观反映了策略表现。上方子图展示了中信建投与中金公司的前复权价格走势。两只股票在样本期内整体趋势一致，但局部存在偏离，这正是配对交易获利的基础。中间子图绘制了 Z-Score 曲线及开仓/平仓阈值线。Z-Score 围绕零值上下波动，多次触及 ± 2.0 的开仓阈值，触发交易信号；当 Z-Score 回归至 ± 0.5 以内时平仓。图中绿色阴影区域表示持仓时段，可见持仓主要发生在价差偏离较大的区间，符合策略逻辑。下方子图对比了策略净值与基准（中信建投单资产净值）。策略净值曲线平稳上升，最终累计收益 36.10%，显著跑赢基准；回撤阶段（最大回撤-11.37%）多对应 Z-Score 极端值时期。




Figure 7: 协整与配对交易回测中信建投与中金公司

协整检验通过验证了中信建投与中金公司价差的均值回归特性，为配对交易提供了理论基础。滚动估计的对冲比率平均值 0.85 反映了市场对两家公司相对估值的平均比例，而其时变性也捕捉到了两者基本面或流动性差异的动态变化。策略取得 36.10% 的累计收益，年化 15.32%，夏普比率 0.9811 略低于 1。与基准相比，策略净值曲线更平滑且最终收益更高，体现了统计套利不依赖市场方向、赚取价差回归绝对收益的优势。